

---

# Chapter 1. 基础知识

---

21307099

liyij323@mail2.sysu.edu.cn

## 1 绪论

### 1.1 最优化

一般描述为:

$$\text{mimize } f(x) \tag{1}$$

$$\text{subject to } x \in \Omega \tag{2}$$

### 1.2 课程内容

- 凸集、凸函数、凸优化问题
- 对偶理论
- 无约束优化: 算法结构、一阶方法、二阶方法
- 有约束优化: 罚方法、增广拉格朗日乘子法、交替方向乘子法
- 现代优化算法

## 2 基础知识

### 2.1 向量

**Definition 1.** 范数 称一个从向量空间  $\mathbb{R}^n$  到实数域  $\mathbb{R}$  的非负函数  $\|\cdot\|$  为范数, 如果

- 
- 正定性  $\|v\| \geq 0, \forall v \in \mathbb{R}^n$  and  $\|v\| = 0 \Leftrightarrow v = 0$
- 齐次性  $\|\alpha v\| = |\alpha| \|v\|, \forall v \in \mathbb{R}^n, \alpha \in \mathbb{R}$
- 三角不等式  $\|v + w\| \leq \|v\| + \|w\|, \forall v, w \in \mathbb{R}^n$

**Definition 2. 相容范数**

满足相容性 (次可乘性) 的范数, 即  $\|AB\| \leq \|A\| \cdot \|B\|$

注意到  $AB, A, B$  可能在不同的空间上, 相容范数应在所有空间上都满足该性质.

对于给定  $v, w$ :

- 内积:  $\langle x, y \rangle = x^T y = \sum_{i=1}^n x_i y_i$
- $\ell_\infty = \max_{1 \leq i \leq n} |x_i|$
- $\ell_p (p \geq 1) : \|x\|_p = (\sum_{i=1}^n |x_i|^p)^{\frac{1}{p}}$
- $\ell_0$  半范:  $\|x\| = (x \text{ 的所有分量中非 } 0 \text{ 元素的个数})$

**Proposition 1.**

$$\forall x \in \mathbb{R} : \|x\|_\infty \leq \|x\|_2 \leq \|x\|_1 \leq n \|x\|_\infty$$

*Cauchy-Schwarz* 不等式:

$$\forall x, y \in \mathbb{R}^n : -\|x\|_2 \|y\|_2 \leq \langle x, y \rangle \leq \|x\|_2 \|y\|_2$$

*Hölder* 不等式:

$$|\langle x, y \rangle| \leq \|x\|_p \|y\|_q, \quad \frac{1}{p} + \frac{1}{q} = 1$$

*Minkowski* 不等式:

$$\forall x, y \in \mathbb{R}^n, p \in [1, \infty)$$

$$\|x + y\|_p \leq \|x\|_p + \|y\|_q$$

**2.2 矩阵**

$$A \in \mathbb{R}^{m \times n}, B \in \mathbb{R}^{m \times n}$$

**Definition 3.** • 内积:  $\langle A, B \rangle = \text{tr}(AB^T)$  即对应位置元素积的和

• Frobenius 范数:  $\|A\| = \sqrt{\sum_{i,j} |a_{ij}|^2} = \sqrt{\text{tr}(A^T A)}$

• 诱导范数

我们希望  $\|AX\| \leq \|A\| \|x\|$ , 故定义

$$\|A\| \triangleq \sup_{\|x\|=1} \|Ax\| = \sup_{\|x\| \neq 0} \frac{\|Ax\|}{\|x\|}$$

- 诱导  $\ell_1$  范数 (最大列和范数)

$$\|A\|_1 = \max_j \sum_i |a_{ij}|$$

- 诱导  $\ell_2$  范数 (谱范数)

$$\|A\|_2 = \sqrt{\lambda_{\max}(A^T A)} = \sigma_{\max}(A)$$

- 诱导  $\ell_\infty$  范数 (最大行和范数)

$$\|A\|_\infty = \max_i \sum_j |a_{ij}|$$

- 核范数

$$\|A\|_* = \sum_{i=1}^r \sigma_i, r = \text{rank} A, \sigma \text{ 为非零奇异值}$$

## 2.3 Basic Concepts In Optimization

**Definition 4.** 最优化问题的数学模型

$$\text{mimize } f(x) \tag{3}$$

$$\text{subject to } x \in \Omega \tag{4}$$

- 决策变量  $x = (x_1, \dots, x_n)^T$

- $f: \Omega \rightarrow \mathbb{R}$

- 可行域 (决策集)  $\Omega \subseteq \mathbb{R}^n$   $\begin{cases} \text{无约束优化问题, } \Omega = \mathbb{R}^n, \\ \text{约束优化问题, } \text{Otherwise.} \end{cases}$

可行域: 等式约束, 不等式约束

$$\Omega = \{x \in \mathbb{R}^n : h(x) = 0, c(x) \leq 0\}$$

### Definition 5.

- 可行域中的点, 或满足约束条件的点称为可行点;
- 对于  $x^* \in \Omega$ , 若对任意的  $x \in \Omega$ , 都有  $f(x^*) \leq f(x)$ , 则称  $x^*$  是问题的一个全局最优解。对应的目标函数值, 即  $f(x^*)$ , 为全局最优值。记为  $x^* \in \arg \min_{x \in \Omega} f(x)$ 。
- 对于局部最优, 若  $x^*$  还满足对任意的  $x \in \Omega \setminus \{x^*\}$ , 都有  $f(x) > f(x^*)$ , 则称  $x^*$  为严格全局最优解;
- 对于  $x^* \in \Omega$ , 若存在  $x^*$  的邻域  $B(x^*, \delta) = \{x : \|x - x^*\| \leq \delta\}$  使得对于任意的  $x \in \Omega \cap B(x^*, \delta)$ , 有  $f(x^*) \leq f(x)$ , 则称  $x^*$  为局部最优解;
- 对于局部最优, 若  $x^*$  满足对任意的  $x \in \Omega \cap B(x^*, \delta), x \neq x^*$ , 有  $f(x) > f(x^*)$ , 则称  $x^*$  为严格局部最优解。

## 2.4 迭代算法

### 基本框架

- 取初始点  $x^0 \in \mathbb{R}^n$  及其他有关参数,  $k = 0$ .
- 验证**停机准则**.
- 给出搜索方向  $d^k \in \mathbb{R}^n$ , 通常要求  $d^k$  是下降方向, 即  $(\nabla f_0(x^k))^T d^k < 0$ .
- 计算迭代步长  $\alpha_k > 0$  使得  $f_0(x^k + \alpha_k d^k) < f_0(x^k)$ .
- $x^{k+1} := x^k + \alpha_k d^k, k := k + 1$ .

## 2.5 最优化问题

### 2.5.1 分类

- 约束优化 & 非约束优化
- 连续优化 & 非连续优化

$$\Omega = \{x \in \mathbb{R}^n : h(x) = 0, c(x) \leq 0\}$$

- 线性规划:  $f, h, c$  都是线性的

- 非线性规划:  $f, h, c$  至少有一个非线性的
- 二次规划:  $f$  是二次函数,  $h, c$  是线性
- 凸优化: 目标函数为凸函数, 可行域为凸集

### 2.5.2 算法评价标准

#### 全局收敛与局部收敛

- 若  $\lim_{k \rightarrow \infty} \|x^k - x^*\| = 0$ , 则称  $x^k$  收敛于  $x^*$
- 子列收敛于  $x^*$ , 称聚点
- 全局收敛性、局部收敛性

#### 收敛速度

1 设算法产生的迭代点列  $x^k$  收敛于  $x^*$ , 即  $x^k \rightarrow x^*$

$$\lim_{k \rightarrow \infty} \frac{\|x^{k+1} - x^*\|}{\|x^k - x^*\|} = \mu$$

- $\mu \in (0, 1)$  称 Q-线性收敛 (Q 表示 quotient (分式), 线性表示误差取对数后, 随迭代步数 k 显线性)
- $\mu = 0$ : Q-超线性收敛,  $\mu = 1$ : Q-次线性收敛

2

$$\lim_{k \rightarrow \infty} \frac{\|x^{k+1} - x^*\|}{\|x^k - x^*\|^p} = \mu, p > 1 \quad \text{称为 Q-p 阶收敛到 } x^*$$

3 R-线性收敛, R-超线性收敛

### 3 凸集 仿射集 凸锥

**Definition 6.** 凸集 Convex Set

过集合  $C$  内任意两点的线段都在  $C$  内, 则称  $C$  为凸集:

$$x_1, x_2 \in C \Rightarrow \theta_1 x_1 + \theta_2 x_2 \in C, \forall \theta_1 + \theta_2 = 1, \theta_1, \theta_2 \geq 0$$

**Definition 7.** 凸组合 Convex Combination

$\theta_i \geq 0$  and  $\sum_{i=1}^m \theta_i = 1$  则称  $\sum_{i=1}^m \theta_i x_i$  为  $x_1, \dots, x_m$  的一个凸组合

**Definition 8.** 仿射集 Affine Set

过集合  $C$  内任意两点的直线都在  $C$  内, 则称  $C$  为仿射集:

$$x_1, x_2 \in C \Rightarrow \theta_1 x_1 + \theta_2 x_2 \in C, \forall \theta_1 + \theta_2 = 1$$

显然仿射集的要求更高, 因此任何仿射集都是凸集, 但凸集未必是仿射集

**Definition 9.** 仿射组合 Affine Combination

$\sum_{i=1}^m \theta_i = 1$  则称  $\sum_{i=1}^m \theta_i x_i$  为  $x_1, \dots, x_m$  的一个仿射组合

**Definition 10.** 凸锥 Convex Cone

$\forall x \in C, \theta \geq 0$ , 都有  $\theta x \in C$ , 则称  $C$  为锥

若  $C$  为凸集, 则称  $C$  为凸锥, 即

$$x_1, x_2 \in C \Rightarrow \theta_1 x_1 + \theta_2 x_2 \in C, \forall \theta_1, \theta_2 \geq 0$$

**Definition 11.** 凸锥组合 Conic Combination

$$\theta_1 \dots \theta_m \geq 0$$

称

$$\sum_{i=1}^m \theta_i x_i$$

为  $x_1 \dots x_m \geq 0$  的一个凸锥组合

**Definition 12.** 凸包 仿射包 凸锥包

集合  $C$  中任意元素的凸组合、仿射组合、凸锥组合称为  $C$  的凸包、仿射包、凸锥包

### 3.1 超平面与半空间

超平面：

$$\{x \in \mathbb{R}^n | a^T x = b\}$$

或者

$$\{x \in \mathbb{R}^n | a^T (x - x_0) = 0\}$$

其中  $x_0$  是超平面上任意一点。超平面是凸集、仿射集，过原点时为凸锥

半空间：

$$\{x \in \mathbb{R}^n | a^T x \leq b\}, a \neq 0$$