

---

# Chapter 1. 基础知识

---

21307099

liyj323@mail2.sysu.edu.cn

## 目录

<b>1 绪论</b>	<b>2</b>
1.1 最优化 . . . . .	2
1.2 课程内容 . . . . .	2
<b>2 基础知识</b>	<b>2</b>
2.1 向量 . . . . .	2
2.2 矩阵 . . . . .	3
2.3 Basic Concepts In Optimization . . . . .	4
2.4 迭代算法 . . . . .	5
2.5 最优化问题 . . . . .	5
2.5.1 分类 . . . . .	5
2.5.2 算法评价标准 . . . . .	6
<b>3 凸集 仿射集 凸锥</b>	<b>7</b>
3.1 仿射维数和相对内部 . . . . .	7
3.2 超平面与半空间 . . . . .	9
3.3 范数球 . . . . .	10
3.4 球和椭球 . . . . .	10
3.5 多面体与单纯形 . . . . .	10
3.6 矩阵空间 . . . . .	11

## 1 绪论

### 1.1 最优化

一般描述为:

$$\text{mimize } f(x) \tag{1}$$

$$\text{subject to } x \in \Omega \tag{2}$$

### 1.2 课程内容

- 凸集、凸函数、凸优化问题
- 对偶理论
- 无约束优化: 算法结构、一阶方法、二阶方法
- 有约束优化: 罚方法、增广拉格朗日乘子法、交替方向乘子法
- 现代优化算法

## 2 基础知识

### 2.1 向量

**Definition 1.** 范数 称一个从向量空间  $\mathbb{R}^n$  到实数域  $\mathbb{R}$  的非负函数  $\|\cdot\|$  为范数, 如果

- 
- 正定性  $\|v\| \geq 0, \forall v \in \mathbb{R} \text{ and } \|v\| = 0 \Leftrightarrow v = 0$
- 齐次性  $\|\alpha v\| = |\alpha| \|v\|, \forall v \in \mathbb{R}^n, \alpha \in \mathbb{R}$
- 三角不等式  $\|v + w\| \leq \|v\| + \|w\|, \forall v, w \in \mathbb{R}^n$

**Definition 2.** 相容范数

满足相容性 (次可乘性) 的范数, 即  $\|AB\| \leq \|A\| \cdot \|B\|$

注意到  $AB, A, B$  可能在不同的空间上, 相容范数应在所有空间上都满足该性质.

对于给定  $v, w$ :

- 内积:  $\langle x, y \rangle = x^T y = \sum_{i=1}^n x_i y_i$
- $\ell_\infty = \max_{1 \leq i \leq n} |x_i|$

- $\ell_p (p \geq 1) : \|x\|_p = (\sum_{i=1}^n |x_i|^p)^{\frac{1}{p}}$
- $\ell_0$  半范 :  $\|x\| = (x \text{ 的所有分量中非 } 0 \text{ 元素的个数})$

**Proposition 1.**

$$\forall x \in \mathbb{R} : \|x\|_\infty \leq \|x\|_2 \leq \|x\|_1 \leq n\|x\|_\infty$$

Cauchy-Schwarz 不等式:

$$\forall x, y \in \mathbb{R}^n : -\|x\|_2 \|y\|_2 \leq \langle x, y \rangle \leq \|x\|_2 \|y\|_2$$

Hölder 不等式:

$$|\langle x, y \rangle| \leq \|x\|_p \|y\|_q, \quad \frac{1}{p} + \frac{1}{q} = 1$$

Minkowski 不等式:

$$\forall x, y \in \mathbb{R}^n, p \in [1, \infty)$$

$$\|x + y\|_p \leq \|x\|_p + \|y\|_q$$

## 2.2 矩阵

$$A \in \mathbb{R}^{m \times n}, B \in \mathbb{R}^{m \times n}$$

**Definition 3.** 矩阵

- 内积:  $\langle A, B \rangle = \text{tr}(AB^T)$  即对应位置元素积的和
- Frobenius 范数:  $\|A\| = \sqrt{\sum_{i,j} |a_{ij}|^2} = \sqrt{\text{tr}(A^T A)}$
- 诱导范数  
我们希望  $\|AX\| \leq \|A\| \|x\|$ , 故定义

$$\|A\| \triangleq \sup_{\|x\|=1} \|Ax\| = \sup_{\|x\| \neq 0} \frac{\|Ax\|}{\|x\|}$$

- 诱导  $\ell_1$  范数 (最大列和范数)

$$\|A\|_1 = \max_j \sum_i |a_{ij}|$$

- 诱导  $\ell_2$  范数 (谱范数)

$$\|A\|_2 = \sqrt{\lambda_{\max}(A^T A)}$$

特别地, 当 A 是 Hermi

- 诱导  $\ell_\infty$  范数 (最大行和范数)

$$\|A\|_1 = \max_i \sum_j |a_{ij}|$$

- 核范数

$$\|A\|_* = \sum_{i=1}^r \sigma_i, r = \text{rank} A, \sigma \text{ 为非零奇异值}$$

**Definition 4.** 正定矩阵

如果对于任意  $x \neq 0, x^T A x > 0$ , 则称  $A$  是正定的, 记为  $A \succ 0$

**Definition 5.** 半正定矩阵

如果对于任意  $x \neq 0, x^T A x \geq 0$ , 则称  $A$  是半正定的, 记为  $A \succeq 0$

$$\forall x \neq 0, x^T A x \geq 0 \quad (3)$$

$$\Rightarrow \forall A \vec{v} = \lambda \vec{v}, v^T A v \geq 0 \quad (4)$$

$$\Rightarrow \lambda v^T v \geq 0 \quad (5)$$

$$\text{Since } v^T v \geq 0 \quad (6)$$

$$\Rightarrow \lambda \geq 0 \quad (7)$$

## 2.3 Basic Concepts In Optimization

**Definition 6.** 最优化问题的数学模型

$$\text{mimize } f(x) \quad (8)$$

$$\text{subject to } x \in \Omega \quad (9)$$

- 决策变量  $x = (x_1, \dots, x_n)^T$

- $f: \Omega \rightarrow \mathbb{R}$

- 可行域 (决策集)  $\Omega \subseteq \mathbb{R}^n \begin{cases} \text{无约束优化问题, } \Omega = \mathbb{R}^n, \\ \text{约束优化问题, } \text{Otherwise.} \end{cases}$

可行域: 等式约束, 不等式约束

$$\Omega = \{x \in \mathbb{R}^n : h(x) = 0, c(x) \leq 0\}$$


### Definition 7.

- 可行域中的点, 或满足约束条件的点称为可行点;
- 对于  $x^* \in \Omega$ , 若对任意的  $x \in \Omega$ , 都有  $f(x^*) \leq f(x)$ , 则称  $x^*$  是问题的一个全局最优解。对应的目标函数值, 即  $f(x^*)$ , 为全局最优值。记为  $x^* \in \arg \min_{x \in \Omega} f(x)$ 。
- 对于局部最优, 若  $x^*$  还满足对任意的  $x \in \Omega \setminus \{x^*\}$ , 都有  $f(x) > f(x^*)$ , 则称  $x^*$  为严格全局最优解;
- 对于  $x^* \in \Omega$ , 若存在  $x^*$  的邻域  $B(x^*, \delta) = \{x : \|x - x^*\| \leq \delta\}$  使得对于任意的  $x \in \Omega \cap B(x^*, \delta)$ , 有  $f(x^*) \leq f(x)$ , 则称  $x^*$  为局部最优解;
- 对于局部最优, 若  $x^*$  满足对任意的  $x \in \Omega \cap B(x^*, \delta), x \neq x^*$ , 有  $f(x) > f(x^*)$ , 则称  $x^*$  为严格局部最优解。

## 2.4 迭代算法

基本框架

- 取初始点  $x^0 \in \mathbb{R}^n$  及其他有关参数,  $k = 0$ .

- 
- 验证**停机准则**.
  - 给出搜索方向  $d^k \in \mathbb{R}^n$ , 通常要求  $d^k$  是下降方向, 即  $(\nabla f_0(x^k))^T d^k < 0$ .
  - 计算迭代步长  $\alpha_k > 0$  使得  $f_0(x^k + \alpha_k d^k) < f_0(x^k)$ .
  - $x^{k+1} := x^k + \alpha_k d^k, k := k + 1$ .

## 2.5 最优化问题

### 2.5.1 分类

- 约束优化 & 非约束优化

- 连续优化 & 非连续优化

$$\Omega = \{x \in \mathbb{R}^n : h(x) = 0, c(x) \leq 0\}$$

- 线性规划:  $f, h, c$  都是线性的
- 非线性规划:  $f, h, c$  至少有一个非线性的
- 二次规划:  $f$  是二次函数,  $h, c$  是线性
- 凸优化: 目标函数为凸函数, 可行域为凸集

## 2.5.2 算法评价标准

### 全局收敛与局部收敛

- 若  $\lim_{k \rightarrow \infty} \|x^k - x^*\| = 0$ , 则称  $x^k$  收敛于  $x^*$
- 子列收敛于  $x^*$ , 称聚点
- 全局收敛性、局部收敛性

### 收敛速度

- 1 设算法产生的迭代点列  $x^k$  收敛于  $x^*$ , 即  $x^k \rightarrow x^*$

$$\lim_{k \rightarrow \infty} \frac{\|x^{k+1} - x^*\|}{\|x^k - x^*\|} = \mu$$

- $\mu \in (0, 1)$  称 Q-线性收敛 (Q 表示 quotient (分式), 线性表示误差取对数后, 随迭代步数 k 显线性)
- $\mu = 0$ : Q-超线性收敛,  $\mu = 1$ : Q-次线性收敛

- 2

$$\lim_{k \rightarrow \infty} \frac{\|x^{k+1} - x^*\|}{\|x^k - x^*\|^p} = \mu, p > 1 \quad \text{称为 Q-p 阶收敛到 } x^*$$

- 3 R-线性收敛, R-超线性收敛

### 3 凸集 仿射集 凸锥

**Definition 8.** 凸集 Convex Set

过集合  $C$  内任意两点的线段都在  $C$  内, 则称  $C$  为凸集:

$$x_1, x_2 \in C \Rightarrow \theta_1 x_1 + \theta_2 x_2 \in C, \forall \theta_1 + \theta_2 = 1, \theta_1, \theta_2 \geq 0$$

**Definition 9.** 凸组合 Convex Combination

$\theta_i \geq 0$  and  $\sum_{i=1}^m \theta_i = 1$  则称  $\sum_{i=1}^m \theta_i x_i$  为  $x_1, \dots, x_m$  的一个凸组合

**Definition 10.** 仿射集 Affine Set

过集合  $C$  内任意两点的直线都在  $C$  内, 则称  $C$  为仿射集:

$$x_1, x_2 \in C \Rightarrow \theta_1 x_1 + \theta_2 x_2 \in C, \forall \theta_1 + \theta_2 = 1$$

显然仿射集的要求更高, 因此任何仿射集都是凸集, 但凸集未必是仿射集

**Definition 11.** 仿射组合 Affine Combination

$\sum_{i=1}^m \theta_i = 1$  则称  $\sum_{i=1}^m \theta_i x_i$  为  $x_1, \dots, x_m$  的一个仿射组合

#### 3.1 仿射维数和相对内部

**Definition 12.** 仿射维数

集合  $C$  的仿射维数为其仿射包的维数。

**Definition 13.** 相对内部

定义集合  $C$  的相对内部为  $\text{aff } C$  的内部, 记为  $\text{relint } C$  即

$$\text{relint } C = \{x \in C \mid B(x, r) \cap \text{aff } C \subseteq C, \exists r > 0\}$$

**Definition 14.** 相对边界

定义集合  $C$  的相对边界为  $\text{cl}C \setminus \text{relint } C$

**Definition 15.** 凸锥 Convex Cone

$\forall x \in C, \theta \geq 0$ , 都有  $\theta x \in C$ , 则称  $C$  为锥

若  $C$  为凸集, 则称  $C$  为凸锥, 即

$$x_1, x_2 \in C \Rightarrow \theta_1 x_1 + \theta_2 x_2 \in C, \forall \theta_1, \theta_2 \geq 0$$

**Definition 16.** 凸锥组合 Conic Combination

$$\theta_1 \dots \theta_m \geq 0$$

称

$$\sum_{i=1}^m \theta_i x_i$$

为  $x_1 \dots x_m \geq 0$  的一个凸锥组合

**Definition 17.** 凸包 仿射包 凸锥包

集合  $C$  中任意元素的凸组合、仿射组合、凸锥组合称为  $C$  的凸包、仿射包、凸锥包



### 3.2 超平面与半空间

超平面：

$$\{x \in \mathbb{R}^n | a^T x = b\}$$

或者


$$\{x \in \mathbb{R}^n | a^T (x - x_0) = 0\}$$

其中  $x_0$  是超平面上任意一点。超平面是凸集、仿射集，过原点时为凸锥

半空间：

$$\{x \in \mathbb{R}^n | a^T x \leq b\}, a \neq 0$$

显然，半空间是凸集，但不是仿射集。过原点时为凸锥



### 3.3 范数球

**Definition 18.** Norm Ball

$$\{x \in \mathbb{R}^n \mid \|x - x_c\|_p \leq r\}$$

显然, 范数球是凸集且当  $r \neq 0$  时不可能是仿射集和凸锥

### 3.4 球和椭球

**Definition 19.** 球

$$b(x_c, r) = \{x \mid \|x - x_c\|_2 \leq r\} \quad (10)$$

$$= \{x \mid \sqrt{(x - x_c)^T (x - x_c)} \leq r\} \quad (11)$$

**Definition 20.** 椭球

$$\mathcal{E} = \{x \in \mathbb{R}^n \mid (x - x_c)^T P^{-1} (x - x_c) \leq 1\}$$

其中  $P = P^T \succ 0$ , 半轴长度由  $\sqrt{\lambda_i}$  给出

例如:

$$x^T \begin{bmatrix} 4 & 0 \\ 0 & 1 \end{bmatrix}^{-1} x \leq 1$$

则

$$\frac{1}{4}x_1^2 + x_2^2 \leq 1$$

特征值为 4 和 1, 则半轴长为 2 和 1

### 3.5 多面体与单纯形

**Definition 21.** 多面体 polyhedron

$$P = \{x \mid a_i^T x \leq b_i, i = 1 \dots m \text{ and } c_j^T x = d_j, j = 1 \dots p\}$$

仿射集合、射线、线段和半空间都是多面体

**Definition 22.** 单纯形 simplex

$v_0, v_1, \dots, v_k$  共  $k+1$  个点仿射无关 (即  $v_1 - v_0, \dots, v_k - v_0$  线性无关), 则

$$C = \text{Conv}\{v_0, v_1, \dots, v_k\}$$

### 3.6 矩阵空间

**Proposition 2.**

1. 对称矩阵集  $S^n$  显然是凸锥、凸集、仿射集
2. 对称半正定矩阵集  $S_+^n$  是凸锥、凸集，不是仿射集（如  $n=1$  时为全体非负实数  $\mathbb{R}_+$ ）
3. 对称正定矩阵集  $S_{++}^n$  是凸集，不是凸锥、仿射集（如  $n=1$  时为全体正实数  $\mathbb{R}_{++}$ ）

对称半正定矩阵是凸锥

Prove:

$$\forall A, B \in S_+^n, \forall x \in \mathbb{R}^n, x^T A x \geq 0, x^T B x \geq 0 \quad (12)$$

$$\forall \theta_0, \theta_1 \geq 0, \quad x^T (\theta_0 A + \theta_1 B) x \quad (13)$$

$$= \theta_0 x^T A x + \theta_1 x^T B x \quad (14)$$

$$\geq 0 \quad (15)$$

显然  $\theta_0, \theta_1$  可以同时 0，因此严格的  $>$  是不满足的，即对称正定矩阵集合不是凸锥（但显然是凸集，因为凸集中  $1^T \vec{\theta} = 1$ ，不能同时取 0）